Assignment 3

Kine Maakestad

Susann Sivertsen

Svar på spørsmål

Spørsmål 1

Filen ddf_concepts.csv inneholder ingen verdier. Det den derimot inneholder er prosentvis av arbeidsledighet, hvor mange barn som har dødd av en alder av 1-59 måneder og nyfødte barn som har dødd.

Spørsmål 2

I denne filen inneholder det også ingen verdier, men filen inneholder land, og hvilken av disse landene som har høy inntekt, middels inntekt og lav inntekt. Den har også med hvor landene ligger i verden, for eksempel så ligger Afghanistan i Asia, og de spesifiserer også at det landet ligger i Sør Asia.

Spørsmål 3

Ddf-entities-geo-un sdg region.csv inneholder de forskjellige regionene og om de er TRUE eller FALSE.

Spørsmål 4

Gapminder pakken inneholder 6 variabler. Disse er:

- Country: faktor med 142 nivåer
- Continent: faktor med 5 nivåer
- Year: områder fra 1952 til 2007 med trinn på 5 år
- Pop: populasjon
- gdpPercap: BNP per innbygger (US\$, inflasjon-justert

Australia og New Zealand ligger i kontinentet Asia.

Spørsmål 5

Her laster vi inn et nytt datasett, og skal deretter flytte Australia og New Zealand fra Asia til Oseania.

```
g_c <- read_csv("data/ddf--entities--geo--country.csv")

## Rows: 273 Columns: 22

## -- Column specification ------

## Delimiter: ","

## chr (17): country, g77_and_oecd_countries, income_3groups, income_groups, is...

## dbl (3): iso3166_1_numeric, latitude, longitude

## lgl (2): is--country, un_state

##

## i Use `spec()` to retrieve the full column specification for this data.

## i Specify the column types or set `show_col_types = FALSE` to quiet this message.

print(g_c)</pre>
```

```
## # A tibble: 273 x 22
                                                                         `is--country`
##
      country
                g77_and_oecd_countries income_3groups income_groups
##
      <chr>
                <chr>
                                        <chr>>
                                                        <chr>>
                                                                         <lgl>
##
   1 abkh
                others
                                        <NA>
                                                        <NA>
                                                                         TRUE
## 2 abw
                others
                                        high income
                                                        high income
                                                                         TRUE
   3 afg
                                                        low income
                                                                         TRUE
##
                g77
                                        low income
## 4 ago
                g77
                                        middle income lower middle i~ TRUE
```

```
## 8 alb
                others
                                       middle_income upper_middle_i~ TRUE
## 9 and
                others
                                       high_income
                                                       high_income
                                                                       TRUE
## 10 ant
                others
                                       <NA>
                                                       <NA>
                                                                       TRUE
## # ... with 263 more rows, and 17 more variables: iso3166_1_alpha2 <chr>,
       iso3166_1_alpha3 <chr>, iso3166_1_numeric <dbl>, iso3166_2 <chr>,
## #
       landlocked <chr>, latitude <dbl>, longitude <dbl>,
## #
       main_religion_2008 <chr>, name <chr>, un_sdg_ldc <chr>,
       un_sdg_region <chr>, un_state <lgl>, unhcr_region <chr>,
       unicef_region <chr>, unicode_region_subtag <chr>, world_4region <chr>,
## #
       world_6region <chr>
spec(g_c)
## cols(
##
     country = col_character(),
##
     g77_and_oecd_countries = col_character(),
##
     income_3groups = col_character(),
##
     income_groups = col_character(),
##
     `is--country` = col_logical(),
##
     iso3166_1_alpha2 = col_character(),
##
     iso3166_1_alpha3 = col_character(),
##
     iso3166_1_numeric = col_double(),
##
     iso3166_2 = col_character(),
##
    landlocked = col_character(),
##
    latitude = col double(),
##
     longitude = col_double(),
##
    main_religion_2008 = col_character(),
##
    name = col_character(),
##
    un_sdg_ldc = col_character(),
    un_sdg_region = col_character(),
##
##
    un_state = col_logical(),
##
    unhcr_region = col_character(),
    unicef_region = col_character(),
##
##
     unicode_region_subtag = col_character(),
##
     world_4region = col_character(),
##
     world_6region = col_character()
I denne har vi flyttet Australia og New Zealand til Oseania, og bare inkludert landene som har
iso3166_1_alpha3 koden.
g_c <- g_c%>%
  mutate(continent = case_when(
    world_4region == "asia" & un_sdg_region %in% c("un_australia_and_new_zealand","un_oceania_exc_austr
   world_4region == "asia" & !(un_sdg_region %in% c("un_australia_and_new_zealand", "un_oceania_exc_au
   world_4region == "africa" ~ "Africa",
   world_4region == "americas" ~ "Americas",
```

<NA>

< NA >

<NA>

<NA>

<NA>

< NA >

TRUE

TRUE

TRUE

Spørsmål 6

world_4region == "europe" ~ "Europe")

filter(!is.na(iso3166 1 alpha3))

5 aia

7 ala

6 akr_a_dhe others

others

others

I dette nye datasettet finner vi ut hvor mange land som er der nå.

58

28

```
length(unique(g_c$country))
## [1] 247
b
Her ser man hvor mange land det nå er i hver kontinent.
g_c %>%
 group_by(continent) %>%
  summarise(countries = length(unique(country)))
## # A tibble: 5 x 2
     continent countries
##
##
     <chr>
                   <int>
## 1 Africa
                       59
## 2 Americas
                       55
## 3 Asia
                       47
```

Spørsmål 7

4 Europe

5 Oceania

Vi laster enda ett nytt datasett, og endrer time variabelen til date. Videre endrer vi time til year.

[1] 195

Spørsmål 8

```
length(unique(lifeExp$geo))
```

[1] 195

Det er 195 land som har informasjon om LifeExp.

Spørsmål 9

Her reduserer vi variablene til country, name, iso3166_1_alpha3, un_sdg_region, world_4region, continent, world_6region.

```
g_c <- g_c %>%
   select(country, name, iso3166_1_alpha3, un_sdg_region, world_4region, continent, world_6region) %>%
   left_join(lifeExp, by = c("country" = "geo"))
names(g_c)
```

```
g_c_min <- g_c %>%
  group_by(country) %>%
  summarise(min_year = min(year))
table(g_c_min$min_year)

##
## 1800-01-01 1950-01-01
## 186 9
```

Den første observasjonen av lifeExp til de forskjellige landene er 186.

Spørsmål 11

Under kan man se at de 9 landene som bare har life expentancy data fra 1950.

```
g_c_min %>%
 filter(min_year == "1950-01-01")
## # A tibble: 9 x 2
##
    country min_year
    <chr> <date>
##
           1950-01-01
## 1 and
## 2 dma
          1950-01-01
## 3 kna
           1950-01-01
## 4 mco
          1950-01-01
## 5 mhl
          1950-01-01
## 6 nru
          1950-01-01
## 7 plw 1950-01-01
## 8 smr
           1950-01-01
## 9 tuv
            1950-01-01
```

Spørsmål 12

Leser her inn et nytt datasett, og endrer til dato.

Spørsmål 13

Leser inn nytt datasett.

```
gdp_pc <- read_csv("data/countries-etc-datapoints/ddf--datapoints--gdppercapita_us_inflation_adjusted--
col_types = cols(time = col_date(format = "%Y")))</pre>
```

```
g_c <- g_c %>%
left_join(gdp_pc, by = c("country" = "geo", "year" = "time"))
```

Endrer her variabel navnene.

```
g_c <- g_c %>%
  rename("lifeExp" = "life_expectancy_years") %>%
  rename("pop" = "population_total") %>%
  rename("gdpPercap" = "gdppercapita_us_inflation_adjusted")
names(g_c)
```

```
## [1] "country" "name" "iso3166_1_alpha3" "un_sdg_region" ## [5] "world_4region" "continent" "world_6region" "year" ## [9] "lifeExp" "pop" "gdpPercap"
```

Spørsmål 14

Her bruker vi dataene fra hver femte år.

```
t1 <- paste(c(seq(1800, 2015, by = 5), 2019), "01-01", sep = "-") %>%
    parse_date(format = "%Y-%m-%d")

g_c_5year <- g_c %>%
    filter(year %in% t1) %>%
    select(country, name, continent, year, lifeExp, pop, gdpPercap)

dim(g_c_5year)

g_c_min_yr_gdp <- g_c_5year %>%
    group_by(gdpPercap) %>%
    summarise (min_year = min(year))

g_c_min_yr_gdp %>%
    count(min_year = g_c_min_yr_gdp$min_year)
```

Spørsmål 15

Chunken under brukes for å vise hvilket år hvert land har innhentet BNP.

```
tmp <- g_c %>%
  filter (!is.na(gdpPercap)) %>%
  group_by(country) %>%
  summarise (nr=n()) %>%
  arrange((country))
```

Videre filtreres det ned til landene som har rapportert BNP over en lengre periode. I dette tilfelle de siste 60 årene:

```
g_c_5year <- tmp %>%
filter(nr > 60)
```

Etter dette kan vi se at det er 84 land som har rapportert BNP de siste 60 årene.

Spørsmål 16

Først i denne oppgaven lager vi ett nytt datasett for å finne observasjonene uten NA verdiene, for å finne antall land med verdier. Her får vi 191 land.

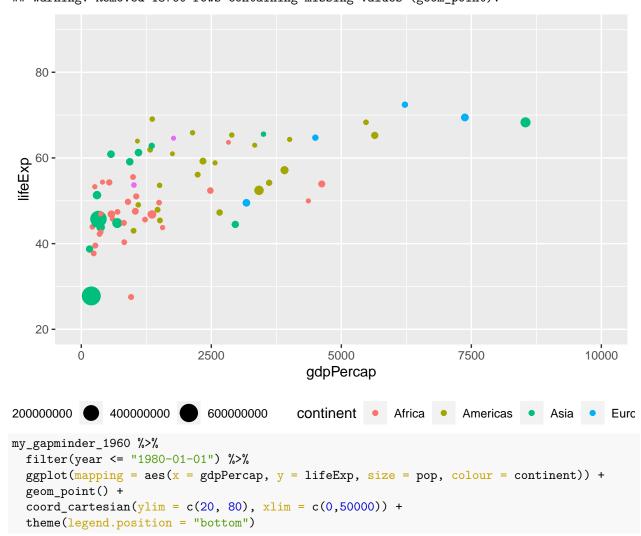
```
c_min_y <- g_c %>%
  filter (!is.na(gdpPercap)) %>%
  group_by(country) %>%
  summarise(min_year = min(year))
dim(c_min_y)
## [1] 191
c_{\min_y}60 \leftarrow c_{\min_y}s_{\min_y}min_year == "1960-01-01"]
my_gapminder_1960 <- g_c %>%
  filter(country %in% c_min_y_60)
dim(my_gapminder_1960)
## [1] 25886
Videre ser man at det er 84 land med registrert data:
length(unique(my_gapminder_1960$country))
## [1] 86
Videre finner vi antall NA verdier:
(num_NA <- my_gapminder_1960[is.na(my_gapminder_1960$gdpPercap) == TRUE, ])</pre>
## # A tibble: 20,647 x 11
##
      country name
                         iso3166_1_alpha3 un_sdg_region
                                                              world_4region continent
##
      <chr>
              <chr>>
                                          <chr>>
                                                              <chr>
                                                                             <chr>
## 1 arg
                                                                             Americas
              Argentina ARG
                                          un_latin_america_~ americas
## 2 arg
              Argentina ARG
                                          un_latin_america_~ americas
                                                                             Americas
                                          un_latin_america_~ americas
## 3 arg
              Argentina ARG
                                                                             Americas
## 4 arg
              Argentina ARG
                                          un_latin_america_~ americas
                                                                             Americas
## 5 arg
              Argentina ARG
                                          un_latin_america_~ americas
                                                                             Americas
## 6 arg
              Argentina ARG
                                          un_latin_america_~ americas
                                                                             Americas
## 7 arg
                                          un_latin_america_~ americas
              Argentina ARG
                                                                             Americas
                                          un_latin_america_~ americas
              Argentina ARG
                                                                             Americas
## 8 arg
## 9 arg
              Argentina ARG
                                          un_latin_america_~ americas
                                                                             Americas
## 10 arg
              Argentina ARG
                                          un_latin_america_~ americas
                                                                             Americas
## # ... with 20,637 more rows, and 5 more variables: world_6region <chr>,
       year <date>, lifeExp <dbl>, pop <dbl>, gdpPercap <dbl>
my_gapminder_1960 %>%
  distinct(country, continent) %>%
  group_by(continent) %>%
  count () %>%
  kable ()
```

continent	n
Africa	29
Americas	25
Asia	14
Europe	15
Oceania	3

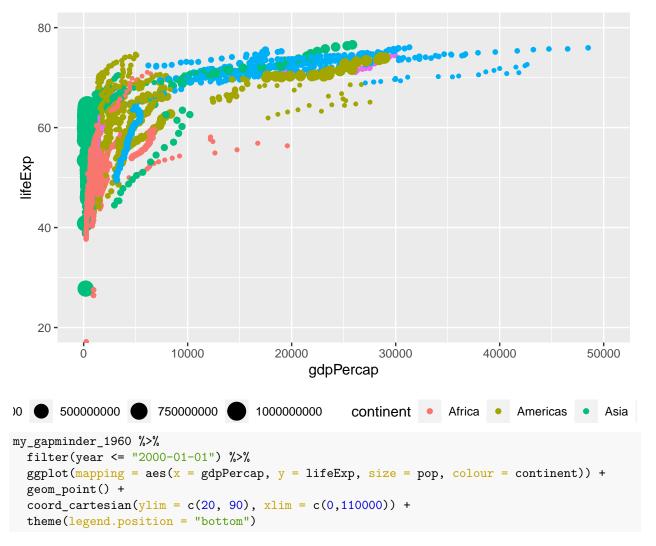
Her bruker vi **ggplot()** for årene 1960, 1980, 2000 og 2019.

```
my_gapminder_1960 %>%
filter(year <= "1960-01-01") %>%
    ggplot(mapping = aes(x = gdpPercap, y = lifeExp, size = pop, colour = continent)) +
    geom_point() +
    coord_cartesian(ylim = c(20, 90), xlim = c(0,10000)) +
    theme(legend.position = "bottom")
```

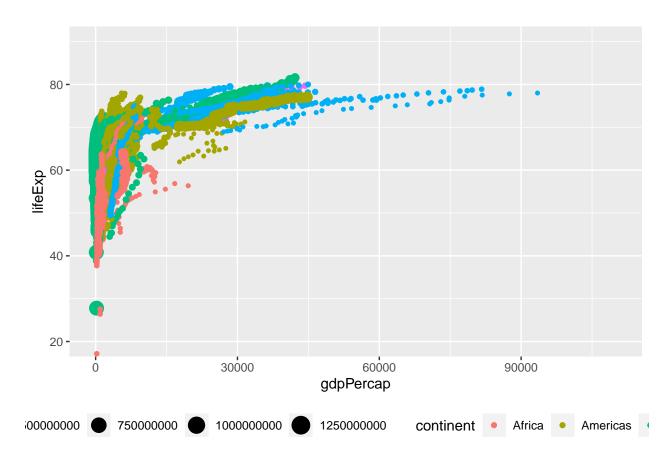
Warning: Removed 13760 rows containing missing values (geom_point).



Warning: Removed 13760 rows containing missing values (geom_point).

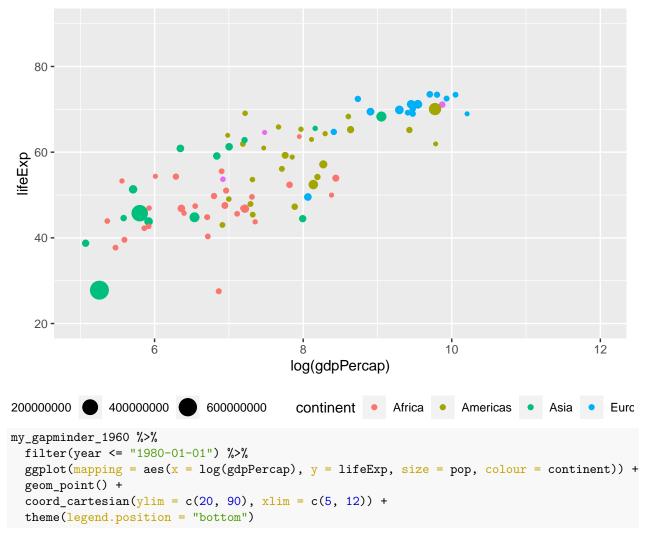


Warning: Removed 13760 rows containing missing values (geom_point).

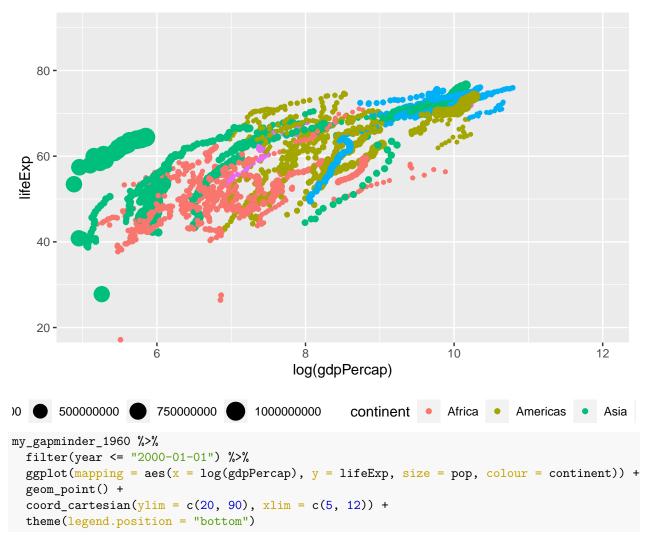


```
my_gapminder_1960 %>%
filter(year <= "1960-01-01") %>%
ggplot(mapping = aes(x = log(gdpPercap), y = lifeExp, size = pop, colour = continent)) +
geom_point() +
coord_cartesian(ylim = c(20, 90), xlim = c(5, 12)) +
theme(legend.position = "bottom")
```

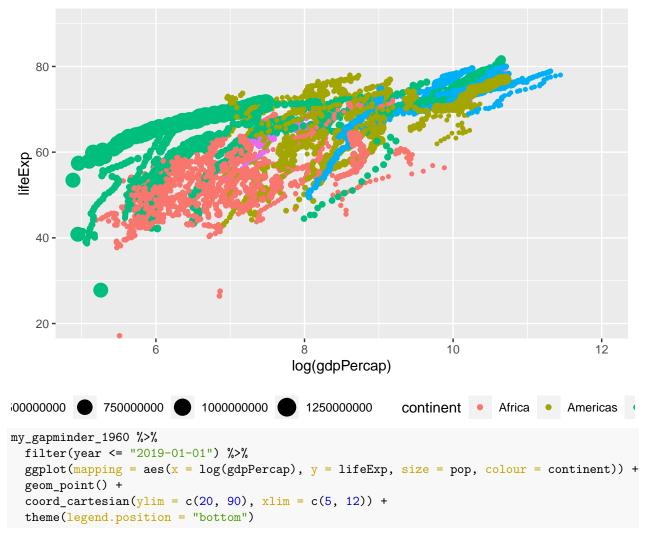
Warning: Removed 13760 rows containing missing values (geom_point).



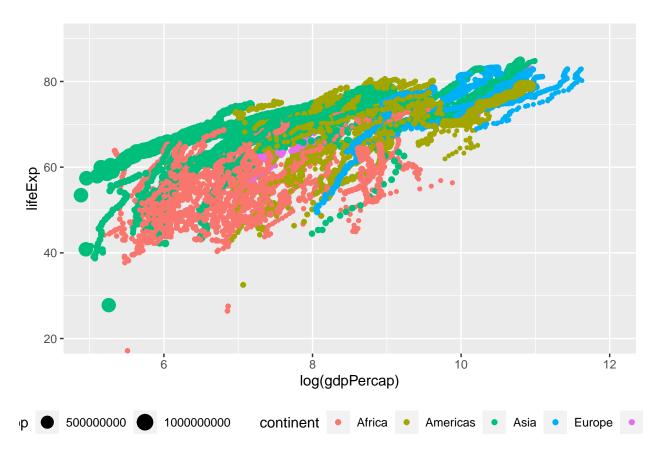
Warning: Removed 13760 rows containing missing values (geom_point).



Warning: Removed 13760 rows containing missing values (geom_point).



Warning: Removed 13765 rows containing missing values (geom_point).



I de siste 59 årene har det vært noen store observasjoner som en kan se. En av dem er at det har vært en stor utvikling i landene og kontinentene som har begynt å rapportere BNP per innbygger.

Spørsmål 20

```
write.table(g_c, file = "my_gapminder.csv", sep = ",")
write.table(g_c_5year, file = "my_gapminder_red.csv", sep = ",")
```