

Assignment 3

Kine Maakestad

Susann Sivertsen

Svar på spørsmål

Spørsmål 1

Filen ddf_concepts.csv inneholder ingen verdier. Det den derimot inneholder er prosentvis av arbeidsledighet, hvor mange barn som har dødd av en alder av 1-59 måneder og nyfødte barn som har dødd.

Spørsmål 2

I denne filen inneholder det også ingen verdier, men filen inneholder land, og hvilken av disse landene som har høy inntekt, middels inntekt og lav inntekt. Den har også med hvor landene ligger i verden, for eksempel så ligger Afghanistan i Asia, og de spesifiserer også at det landet ligger i Sør Asia.

Spørsmål 3

Ddf-entities-geo-un_sdg_region.csv inneholder de forskjellige regionene og om de er TRUE eller FALSE.

Spørsmål 4

Gapminder pakken inneholder 6 variabler. Disse er:

- Country: faktor med 142 nivåer
- Continent: faktor med 5 nivåer
- Year: områder fra 1952 til 2007 med trinn på 5 år
- Pop: populasjon
- gdpPercap: BNP per innbygger (US\$, inflasjon-justert)

Australia og New Zealand ligger i kontinentet Asia.

Spørsmål 5

Her laster vi inn et nytt datasett, og skal deretter flytte Australia og New Zealand fra Asia til Oceania.

```
g_c <- read_csv("data/ddf--entities--geo--country.csv")

## Rows: 273 Columns: 22

## -- Column specification -----
## Delimiter: ","
## chr (17): country, g77_and_oecd_countries, income_3groups, income_groups, is...
## dbl (3): iso3166_1_numeric, latitude, longitude
## lgl (2): is--country, un_state

##
## i Use 'spec()' to retrieve the full column specification for this data.
## i Specify the column types or set 'show_col_types = FALSE' to quiet this message.

print(g_c)
```

```
## # A tibble: 273 x 22
##   country    g77_and_oecd_countries income_3groups income_groups 'is--country'
##   <chr>      <chr>                  <chr>         <chr>         <lgl>
## 1 abkh      others                  <NA>         <NA>         TRUE
## 2 abw       others                  high_income   high_income   TRUE
## 3 afg       g77                     low_income    low_income    TRUE
## 4 ago       g77                     middle_income lower_middle_i~ TRUE
```

```
## 5 aia      others      <NA>      <NA>      TRUE
## 6 akr_a_dhe others      <NA>      <NA>      TRUE
## 7 ala      others      <NA>      <NA>      TRUE
## 8 alb      others      middle_income upper_middle_i~ TRUE
## 9 and      others      high_income  high_income  TRUE
## 10 ant     others      <NA>      <NA>      TRUE
## # ... with 263 more rows, and 17 more variables: iso3166_1_alpha2 <chr>,
## #   iso3166_1_alpha3 <chr>, iso3166_1_numeric <dbl>, iso3166_2 <chr>,
## #   landlocked <chr>, latitude <dbl>, longitude <dbl>,
## #   main_religion_2008 <chr>, name <chr>, un_sdg_ldc <chr>,
## #   un_sdg_region <chr>, un_state <lgl>, unhcr_region <chr>,
## #   unicef_region <chr>, unicode_region_subtag <chr>, world_4region <chr>,
## #   world_6region <chr>
```

```
spec(g_c)
```

```
## cols(
##   country = col_character(),
##   g77_and_oecd_countries = col_character(),
##   income_3groups = col_character(),
##   income_groups = col_character(),
##   'is--country' = col_logical(),
##   iso3166_1_alpha2 = col_character(),
##   iso3166_1_alpha3 = col_character(),
##   iso3166_1_numeric = col_double(),
##   iso3166_2 = col_character(),
##   landlocked = col_character(),
##   latitude = col_double(),
##   longitude = col_double(),
##   main_religion_2008 = col_character(),
##   name = col_character(),
##   un_sdg_ldc = col_character(),
##   un_sdg_region = col_character(),
##   un_state = col_logical(),
##   unhcr_region = col_character(),
##   unicef_region = col_character(),
##   unicode_region_subtag = col_character(),
##   world_4region = col_character(),
##   world_6region = col_character()
## )
```

I denne har vi flyttet Australia og New Zealand til Oseania, og bare inkludert landene som har iso3166_1_alpha3 koden.

```
g_c <- g_c%>%
  mutate(continent = case_when(
    world_4region == "asia" & un_sdg_region %in% c("un_australia_and_new_zealand", "un_oceania_exc_austr") ~ "Oceania",
    world_4region == "asia" & !(un_sdg_region %in% c("un_australia_and_new_zealand", "un_oceania_exc_austr")) ~ "Asia",
    world_4region == "africa" ~ "Africa",
    world_4region == "americas" ~ "Americas",
    world_4region == "europe" ~ "Europe")
  ) %>%
  filter(!is.na(iso3166_1_alpha3))
```

Spørsmål 6

a

I dette nye datasettet finner vi ut hvor mange land som er der nå.

```
length(unique(g_c$country))
```

```
## [1] 247
```

b

Her ser man hvor mange land det nå er i hver kontinent.

```
g_c %>%  
  group_by(continent) %>%  
  summarise(countries = length(unique(country)))
```

```
## # A tibble: 5 x 2  
##   continent countries  
##   <chr>         <int>  
## 1 Africa          59  
## 2 Americas        55  
## 3 Asia            47  
## 4 Europe          58  
## 5 Oceania         28
```

Spørsmål 7

Vi laster enda ett nytt datasett, og endrer **time** variabelen til **date**. Videre endrer vi **time** til **year**.

```
lifeExp <- read_csv("data/countries-etc-datapoints/ddf--datapoints--life_expectancy_years--by--geo--time")  
col_types = cols(time = col_date(format = "%Y"))  
lifeExp <- lifeExp %>%  
  rename(year = time)  
names(lifeExp)
```

```
## [1] "geo"          "year"         "life_expectancy_years"  
length(unique(lifeExp$geo))
```

```
## [1] 195
```

Spørsmål 8

```
length(unique(lifeExp$geo))
```

```
## [1] 195
```

Det er 195 land som har informasjon om LifeExp.

Spørsmål 9

Her reduserer vi variablene til **country**, **name**, **iso3166_1_alpha3**, **un_sdg_region**, **world_4region**, **continent**, **world_6region**.

```
g_c <- g_c %>%  
  select(country, name, iso3166_1_alpha3, un_sdg_region, world_4region, continent, world_6region) %>%
```

```
left_join(lifeExp, by = c("country" = "geo"))
names(g_c)
```

```
## [1] "country"          "name"              "iso3166_1_alpha3"
## [4] "un_sdg_region"    "world_4region"     "continent"
## [7] "world_6region"    "year"              "life_expectancy_years"
```

Spørsmål 10

```
g_c_min <- g_c %>%
  group_by(country) %>%
  summarise(min_year = min(year))
table(g_c_min$min_year)
```

```
##
## 1800-01-01 1950-01-01
##          186          9
```

Den første observasjonen av lifeExp til de forskjellige landene er 186.

Spørsmål 11

Under kan man se at de 9 landene som bare har **life expentancy** data fra 1950.

```
g_c_min %>%
  filter(min_year == "1950-01-01")
```

```
## # A tibble: 9 x 2
##   country min_year
##   <chr>   <date>
## 1 and     1950-01-01
## 2 dma     1950-01-01
## 3 kna     1950-01-01
## 4 mco     1950-01-01
## 5 mhl     1950-01-01
## 6 nru     1950-01-01
## 7 plw     1950-01-01
## 8 smr     1950-01-01
## 9 tuv     1950-01-01
```

Spørsmål 12

Leser her inn et nytt datasett, og endrer til dato.

```
pop <- read_csv("data/countries-etc-datapoints/ddf--datapoints--population_total--by--geo--time.csv",
  col_types = cols(time = col_date(format = "%Y")))
```

```
g_c <- g_c %>%
  left_join(pop, by = c("country" = "geo", "year" = "time"))
rm(pop)
```

Spørsmål 13

Leser inn nytt datasett.

```
gdp_pc <- read_csv("data/countries-etc-datapoints/ddf--datapoints--gdppercapita_us_inflation_adjusted--")
col_types = cols(time = col_date(format = "%Y"))
```

```
g_c <- g_c %>%
  left_join(gdp_pc, by = c("country" = "geo", "year" = "time"))
```

Endrer her variabel navnene.

```
g_c <- g_c %>%
  rename("lifeExp" = "life_expectancy_years") %>%
  rename("pop" = "population_total") %>%
  rename("gdpPercap" = "gdppercapita_us_inflation_adjusted")
names(g_c)
```

```
## [1] "country"          "name"              "iso3166_1_alpha3" "un_sdg_region"
## [5] "world_4region"    "continent"         "world_6region"    "year"
## [9] "lifeExp"          "pop"               "gdpPercap"
```

Spørsmål 14

Her bruker vi dataene fra hver femte år.

```
t1 <- paste(c(seq(1800, 2015, by = 5), 2019), "01-01", sep = "-") %>%
  parse_date(format = "%Y-%m-%d")
```

```
g_c_5year <- g_c %>%
  filter(year %in% t1) %>%
  select(country, name, continent, year, lifeExp, pop, gdpPercap)
```

```
dim(g_c_5year)
```

```
g_c_min_yr_gdp <- g_c_5year %>%
  group_by(gdpPercap) %>%
  summarise (min_year = min(year))
```

```
g_c_min_yr_gdp %>%
  count(min_year = g_c_min_yr_gdp$min_year)
```

Spørsmål 15

Chunken under brukes for å vise hvilket år hvert land har innhentet BNP.

```
tmp <- g_c %>%
  filter (!is.na(gdpPercap)) %>%
  group_by(country) %>%
  summarise (nr=n()) %>%
  arrange((country))
```

Videre filtreres det ned til landene som har rapportert BNP over en lengre periode. I dette tilfelle de siste 60 årene:

```
g_c_5year <- tmp %>%
  filter(nr > 60)
```

Etter dette kan vi se at det er 84 land som har rapportert BNP de siste 60 årene.

Spørsmål 16

Først i denne oppgaven lager vi ett nytt datasett for å finne observasjonene for å finne antall land med verdier i tidsperioden 1960-2019. Her finner vi 191 land.

```
c_min_y <- g_c %>%
  filter (!is.na(gdpPercap)) %>%
  group_by(country) %>%
  summarise(min_year = min(year))

dim(c_min_y)
```

```
## [1] 190    2
```

Her ser vi at i my_gapminder_1960 datasettet er det 25886 observasjoner og 11 variabler.

```
c_min_y_60 <- c_min_y$country[c_min_y$min_year == "1960-01-01"]
my_gapminder_1960 <- g_c %>%
  filter(country %in% c_min_y_60)

dim(my_gapminder_1960)
```

```
## [1] 25585    11
```

Videre ser man at det er 86 land med registrert data:

```
length(unique(my_gapminder_1960$country))
```

```
## [1] 85
```

Videre finner vi oversikt over NA verdier:

```
(num_NA <- my_gapminder_1960[is.na(my_gapminder_1960$gdpPercap) == TRUE, ])
```

```
## # A tibble: 20,400 x 11
##   country name      iso3166_1_alpha3 un_sdg_region      world_4region continent
##   <chr>      <chr>      <chr>          <chr>          <chr>      <chr>
## 1 arg      Argentina ARG          un_latin_america_~ americas    Americas
## 2 arg      Argentina ARG          un_latin_america_~ americas    Americas
## 3 arg      Argentina ARG          un_latin_america_~ americas    Americas
## 4 arg      Argentina ARG          un_latin_america_~ americas    Americas
## 5 arg      Argentina ARG          un_latin_america_~ americas    Americas
## 6 arg      Argentina ARG          un_latin_america_~ americas    Americas
## 7 arg      Argentina ARG          un_latin_america_~ americas    Americas
## 8 arg      Argentina ARG          un_latin_america_~ americas    Americas
## 9 arg      Argentina ARG          un_latin_america_~ americas    Americas
## 10 arg     Argentina ARG          un_latin_america_~ americas    Americas
## # ... with 20,390 more rows, and 5 more variables: world_6region <chr>,
## #   year <date>, lifeExp <dbl>, pop <dbl>, gdpPercap <dbl>
```

Til slutt finner hvor mange land det er fra hvert kontinent i datasettet:


```
my_gapminder_1960 %>%
  distinct(country, continent) %>%
  group_by(continent) %>%
  count () %>%
  kable ()
```

continent	n
Africa	29
Americas	24
Asia	14
Europe	15
Oceania	3

Spørsmål 17

Her bruker vi `ggplot()` for årene 1960, 1980, 2000 og 2019.

```
my_gapminder_1960 %>%
  # ok med <= siden vi starter 1960, men kanskje bedre med == så er det lettere å
  # forstå hva vi gjør
  filter(year == "1960-01-01") %>%
  ggplot(mapping = aes(x = gdpPercap, y = lifeExp, size = pop, colour = continent)) +
  geom_point() +
  # satt samme xlim som nedenfor. lettere å sammenligne
  coord_cartesian(ylim = c(20, 90), xlim = c(0, 110000)) +
  theme(legend.position = "bottom")
```




2000000000 ● 4000000000 ● 6000000000 continent ● Africa ● Americas ● Asia ● Eurc

```
my_gapminder_1960 %>%
  # data for år 1980
  filter(year == "1980-01-01") %>%
  ggplot(mapping = aes(x = gdpPercap, y = lifeExp, size = pop, colour = continent)) +
  # alternativ måte å sette xlim og ylim. Bruker samme på alle så lettere å se utviklingen
  xlim(0, 110000) +
```




```
ylim(20,90) +
geom_point() +
#coord_cartesian(ylim = c(20, 80), xlim = c(0,50000)) +
theme(legend.position = "bottom")
```



10 ● 500000000 ● 750000000 ● 1000000000 continent ● Africa ● Americas ● Asia

```
# Denne er litt kul, men blir kanskje litt "crowded"
my_gapminder_1960 %>%
  filter(year <= "2000-01-01") %>%
  ggplot(mapping = aes(x = gdpPercap, y = lifeExp, size = pop, colour = continent)) +
  geom_point() +
  coord_cartesian(ylim = c(20, 90), xlim = c(0,110000)) +
  theme(legend.position = "bottom")
```


```
## Warning: Removed 13600 rows containing missing values (geom_point).
```



000000000 ● 750000000 ● 1000000000 ● 1250000000 continent ● Africa ● Americas ● Europe

```


my_gapminder_1960 %>%
  filter(year == "2000-01-01") %>%
  ggplot(mapping = aes(x = gdpPerCap, y = lifeExp, size = pop, colour = continent)) +
  geom_point() +
  coord_cartesian(ylim = c(20, 90), xlim = c(0, 110000)) +
  theme(legend.position = "bottom")
  
```



12500000000 ● 7500000000 ● 10000000000 ● 12500000000 continent ● Africa ● Americas ● Europe

```

my_gapminder_1960 %>%
  filter(year == "2019-01-01") %>%
  ggplot(mapping = aes(x = gdpPercap, y = lifeExp, size = pop, colour = continent)) +
  geom_point() +
  coord_cartesian(ylim = c(20, 90), xlim = c(0, 110000)) +
  theme(legend.position = "bottom")
  
```




p ● 500000000 ● 1000000000 continent ● Africa ● Americas ● Asia ● Europe ●

Spørsmål 18


Her bruker vi log i ggplottene.

```
my_gapminder_1960 %>%
  filter(year == "1960-01-01") %>%
  ggplot(mapping = aes(x = log(gdpPercap), y = lifeExp, size = pop, colour = continent)) +
  geom_point() +
  coord_cartesian(ylim = c(20, 90), xlim = c(5, 12)) +
  theme(legend.position = "bottom")
```




200000000 ● 400000000 ● 600000000 continent ● Africa ● Americas ● Asia ● Eurc

```
my_gapminder_1960 %>%
  filter(year == "1980-01-01") %>%
  ggplot(mapping = aes(x = log(gdpPercap), y = lifeExp, size = pop, colour = continent)) +
  geom_point() +
  coord_cartesian(ylim = c(20, 90), xlim = c(5, 12)) +
  theme(legend.position = "bottom")
```



10 ● 500000000 ● 750000000 ● 1000000000 continent ● Africa ● Americas ● Asia


```
my_gapminder_1960 %>%
  filter(year == "2000-01-01") %>%
  ggplot(mapping = aes(x = log(gdpPercap), y = lifeExp, size = pop, colour = continent)) +
  geom_point() +
  coord_cartesian(ylim = c(20, 90), xlim = c(5, 12)) +
  theme(legend.position = "bottom")
```



000000000 ● 750000000 ● 1000000000 ● 1250000000 continent ● Africa ● Americas ● Europe

```

my_gapminder_1960 %>%
  filter(year == "2019-01-01") %>%
  ggplot(mapping = aes(x = log(gdpPerCap), y = lifeExp, size = pop, colour = continent)) +
  geom_point() +
  coord_cartesian(ylim = c(20, 90), xlim = c(5, 12)) +
  theme(legend.position = "bottom")
  
```



Spørsmål 19

I de siste 59 årene har det vært noen store observasjoner som man kan se. Man kan se at det er en økning i antall land som rapporterer BNP per innbygger. Man ser god ut en stor utvikling i landene og kontinentene som rapporterer BNP per innbygger.

Spørsmål 20

```
write.table(g_c, file = "my_gapminder.csv", sep = ",")
write.table(g_c_5year, file = "my_gapminder_red.csv", sep = ",")
```